# Résumé automatique

Projet en «NLP: Natural Language Processing»

Réalisé par :

Abdallah ben othmen trabelsi

Proposé par :

Dr. Abir MASMOUDI



#### Année universitaire 2022-2023

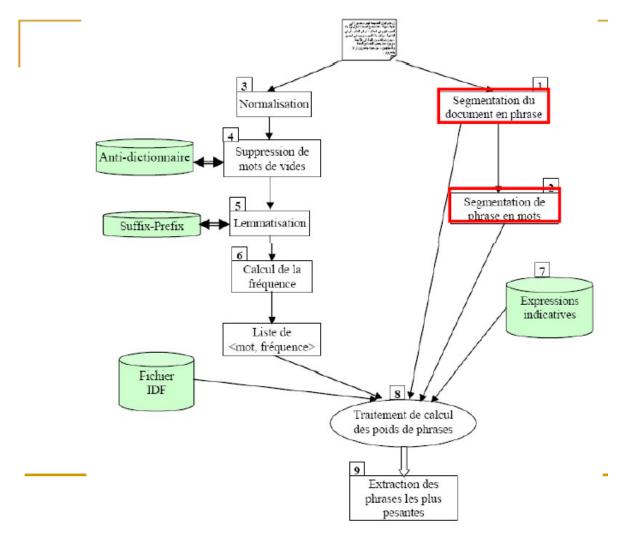
## Résumé automatique

#### I. Contexte et objectif

En se basant sur la méthode de résumé automatique présentée dans le cours, développer un système de résumé automatique qui se base sur la fréquence des mots et les mots des titres pour extraire les phrases les plus pertinentes (importantes). Le système affiche à la fin les phrases les plus pertinentes.

Langage de programmation : Python

Rappel de la méthode de résumé automatique vue dans le cours :



#### II. Travail demandé:

Dans ce travail, nous proposons de suivre les étapes suivantes pour réaliser ce projet.

- Importer les bibliothèques (NLTK et autres si nécessaires)

```
import bs4 as bs
import urllib.request
import re
import nltk
nltk.download()
```

- Chargement du texte à partir du technique web scraping

## Récupérer des articles de Wikipedia (SCRAPING)

```
import bs4 as bs
import urllib.request
import re

scraped_data = urllib.request.urlopen('https://en.wikipedia.org/wiki/Natural_language_processing')
article = scraped_data.read()

parsed_article = bs.BeautifulSoup(article,'lxml')

paragraphs = parsed_article.find_all('p')
article_text = ""

for p in paragraphs:
    article_text += p.text
```

- Suppression des crochets et des espaces supplémentaires

```
# Removing Square Brackets and Extra Spaces
article_text = re.sub(r'\[[0-9]*\]', ' ', article_text)
article_text = re.sub(r'\s+', ' ', article_text)
✓ 0.7s
```

- Suppression des caractères spéciaux et des chiffres

 Segmenter les phrases en mots tokenistion (fonction prédéfinie tokenize())

### 

```
sentence_list = nltk.sent_tokenize(article_text)
```

- Détecter les stopWords (mots vides) (fonction prédéfinie pour les
- stopWords) & Calculer pour chaque mot sa fréquence (sauvegarder les résultats dans une structure)

```
stopwords = nltk.corpus.stopwords.words('english')
   word_frequencies = {}
   for word in nltk.word_tokenize(formatted_article_text):
       if word not in stopwords:
           if word not in word frequencies.keys():
               word_frequencies[word] = 1
           else:
               word_frequencies[word] += 1
    0.85
   word_frequencies
 ✓ 0.6s
Output exceeds the size limit. Open the full output data in a text editor
{'Natural': 0.07142857142857142,
 'language': 1.0,
 'processing': 0.5714285714285714,
 'NLP': 0.6071428571428571,
 'subfield': 0.03571428571428571,
 'linguistics': 0.32142857142857145,
 'computer': 0.14285714285714285,
 'science': 0.10714285714285714,
 'artificial': 0.07142857142857142,
 'intelligence': 0.10714285714285714,
```

- Calculer les poids des phrases en fonction de la présence de mots

- fréquents au sein de chaque phrase (sauvegarder les valeurs des poids)
- Trier les phrases selon leurs poids
- Réordonner les phrases selon leur ordre chronologique du texte original

```
Obtenir le résumé

import heapq
summary_sentences = heapq.nlargest(7, sentence_scores, key=sentence_scores.get)

summary = ' '.join(summary_sentences)
print(summary)

✓ 0.4s

Starting in the late 1980s, however, there was a revolution in natural language processing with the introduction of machine learning algorithms for language processing. In the 2010s, representation learning and deep neural network-style machine learning methods became widespread in natural language processing. That popularity was due partly to a flurry of results showing that such techniques can achieve state-of-the-art results in many natural language tasks, e.g., in language modeling and parsing. Up to the 1980s, most natural language processing systems were based on complex sets of hand-written rules. The cache language models upon which many speech recognition systems now rely are examples of such statistical models. Challenges in natural language processing frequently involve speech recognition, natural-language understanding, and natural-language generation. The following is a list of some of the most commonly researched tasks in natural language processing.
```

#### III. Travail à faire

- Comme convenu lors de la séance du 19/10/22, vous êtes amenés à présenter, lors de la séance du 09/11/22, un programme Python qui réalisera le résumé d'un texte en utilisant plusieurs critères de sélection des phrases. Vous suivez globalement les étapes qui ont été données dans le chapitre "Résumé Automatique (Bis)".
- Le travail sera élaboré par monôme ou par binôme.
- Vous allez présenter vos travaux le Mercredi 09/11/22.
- Un compte-rendu comportant les différentes parties du programme Python que vous allez coder ainsi que des images écran illustratives de l'exécution doit être envoyé par mail au plus tard le 08/11/22 à 20h.

NB: Le compte rendu dans un fichier pdf. Dans ce compte rendu, vous mettez les étapes qu'assure votre système. Pour chaque étape, vous donnez une brève description et vous illustrez son résultat à travers une image écran.

